计算题：

· 基本概念计算（各种距离、各种相似度、Precision、Recall、ACC、F1）

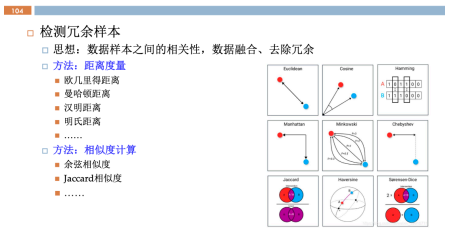

分类——模型评估方法：混淆矩阵

		PREDICTED CLASS	
		Class=Yes	Class=No
ACTUAL CLASS	Class=Yes	a (TP)	b (FN)
	Class=No	c (FP)	d (TN)

Most widely-used metric

$$\text{Accuracy} = \frac{a+d}{a+b+c+d} = \frac{TP+TN}{TP+TN+FP+FN}$$

正确率 $\text{Precision (p)} = \frac{a}{a+c}$

召回率 $\text{Recall (r)} = \frac{a}{a+b}$

F值 $\text{F-measure (F)} = \frac{2rp}{r+p} = \frac{2a}{2a+b+c}$

Count	PREDICTED CLASS		
		Class=Yes	Class=No
ACTUAL CLASS	Class=Yes	a	b
	Class=No	c	d

· 计算Spearman相关系数、CG、DCG、NDCG

· PCA和TF-IDF忘了有没有了？，但也挺重要的，需要看一看

· 参数估计——抛硬币

  · 似然估计

  · 最大后验估计（Beta分布）

参数估计——最大后验估计

61

- 最大后验概率估计(MAP)—理解先验p(θ)
  - 扔硬币的例子：我们期望先验概率（待估计的参数$\boldsymbol{\theta}$）分布在0.5处取得最大值，也可以选用**Beta分布**（θ服从Beta分布）即：

$$p(\theta|\alpha,\beta) \triangleq Beta(\alpha,\beta) = \frac{1}{B(\alpha,\beta)}\theta^{\alpha-1}(1-\theta)^{\beta-1}$$

  - 其中，Beta函数是 $B(\alpha,\beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
  - Gamma函数 $\Gamma(n) = (n-1)!$
  - Beta分布的随机变量范围是[0,1]，不同参数情况下的Beta分布的概率密度函数形式如图

参数估计—最大后验估计

63

- 最大后验概率估计(MAP)—理解先验p(θ)
  - 扔硬币的例子：我们期望待估计的参数θ的先验分布在0.5处取得最大值，可以选用**Beta分布**（θ服从Beta分布）即：

$$p(\theta|\alpha,\beta) \triangleq Beta(\alpha,\beta) = \frac{1}{B(\alpha,\beta)}\theta^{\alpha-1}(1-\theta)^{\beta-1}$$

  - 取 $\boldsymbol{\alpha} = \boldsymbol{\beta} = 5$，使得先验分布Beta分布在0.5处取得最大值
  - **使用MAP方法求解参数**

· 贝叶斯估计

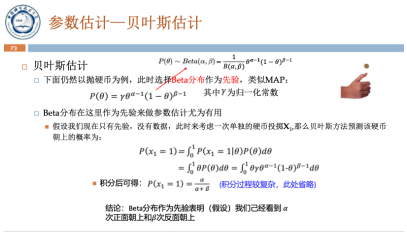

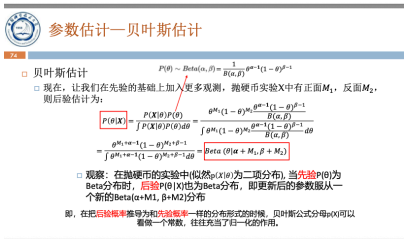

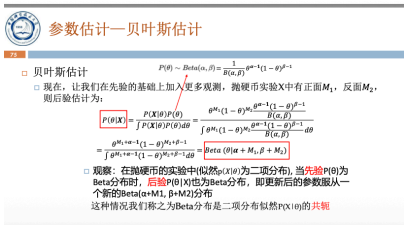

关联规则中的若干概念计算：

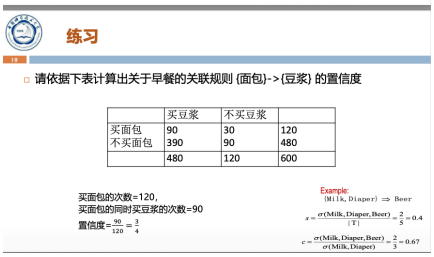

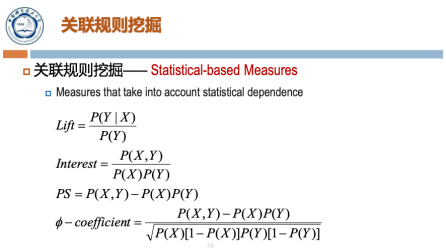

A–Priori算法

略

决策树（信息熵、信息增益、基尼指数、Error、如何利用这些指标分裂）

略

贝叶斯分类器（类似下图的一道题）

贝叶斯分类器

135

For example:

Name	Give Birth	Can Fly	Live in Water	Have Legs	Class
human	yes	no	no	yes	mammals
python	no	no	no	no	non-mammals
salmon	no	no	yes	no	non-mammals
whale	yes	no	yes	no	mammals
frog	no	no	sometimes	yes	non-mammals
komodo	no	no	no	yes	non-mammals
bat	yes	yes	no	yes	mammals
pigeon	no	yes	no	yes	non-mammals
cat	yes	no	no	yes	mammals
leopard shark	yes	no	yes	no	non-mammals
turtle	no	no	sometimes	yes	non-mammals
penguin	no	no	sometimes	yes	non-mammals
porcupine	yes	no	no	yes	mammals
eel	no	no	yes	no	non-mammals
salamander	no	no	sometimes	yes	non-mammals
gila monster	no	no	no	yes	non-mammals
platypus	no	no	no	yes	mammals
owl	no	yes	no	yes	non-mammals
dolphin	yes	no	yes	no	mammals
eagle	no	yes	no	yes	non-mammals

A

Give Birth	Can Fly	Live in Water	Have Legs	Class
yes	no	yes	no	?

A: attributes

M: mammals

N: non-mammals

$$P(A|M)=\frac{6}{7}\times\frac{6}{7}\times\frac{2}{7}\times\frac{2}{7}=0.06$$

$$P(A|N)=\frac{1}{13}\times\frac{10}{13}\times\frac{3}{13}\times\frac{4}{13}=0.0042$$

$$P(A|M)P(M)=0.06\times\frac{7}{20}=0.021$$

$$P(A|N)P(N)=0.004\times\frac{13}{20}=0.0027$$

P(A|M)P(M) > P(A|N)P(N)

=> Mammals

感知机（PPT原题⬇️）

例 如图3所示的训练数据集，其正实例点是$x_1=(3,3)^T$，$x_2=(4,3)^T$，负实例点是$x_3=(1,1)^T$，试用感知机学习算法的原始形式求感知机模型$f(x)=sign(w\cdot x+b)$，即求出w和b。这里$w=(w^{(1)},w^{(2)})^T$，$x=(x^{(1)},x^{(2)})^T$

假设错分类点定义为

$$y_i(w\cdot x_i+b)\leqslant 0$$

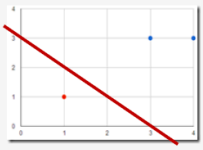

假设学习速率为**1**，则每步更新为：

$w=w+y_ix_i$

$b=b+y_i$

迭代次数	误分类点	w	b	$w\cdot x+b$
0		0	0	0
1	x_1	$(3,3)^T$	1	$3x^{(1)}+3x^{(2)}+1$
2	x_3	$(2,2)^T$	0	$2x^{(1)}+2x^{(2)}$
3	x_3	$(1,1)^T$	−1	$x^{(1)}+x^{(2)}-1$
4	x_3	$(0,0)^T$	−2	−2
5	x_1	$(3,3)^T$	−1	$3x^{(1)}+3x^{(2)}-1$
6	x_3	$(2,2)^T$	−2	$2x^{(1)}+2x^{(2)}-2$
7	x_3	$(1,1)^T$	−3	$x^{(1)}+x^{(2)}-3$
8	0	$(1,1)^T$	−3	$x^{(1)}+x^{(2)}-3$

注：ARIMA、ETS、Theta我没印象，疑似是今年新加的内容

简答题：

· 原题⬇️

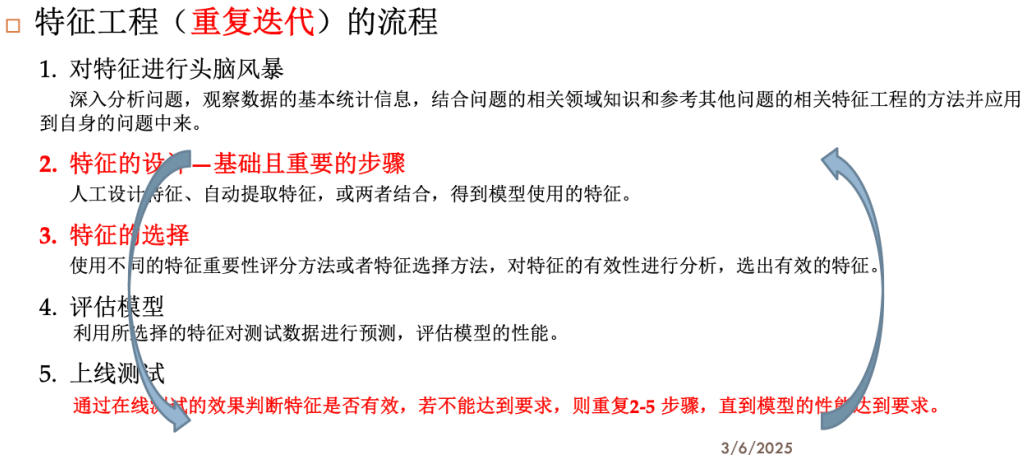

· 结构化数据、半结构化数据、非结构化数据的定义与区别

· 其它忘了

其它：

除了第一章以及太偏机器学习的内容（如SVM）不会考，其它基本概念和方法都可能出现在选择、简答中，不过在我印象中都不难